



**TECNOLÓGICO
NACIONAL DE MÉXICO**

Instituto Tecnológico de Culiacán

**Paradigmas de la IA y Proceso de aprendizaje
automático**

Inteligencia Artificial

Zuriel Dathan Mora Felix

Integrantes:

Trapero Orona Cristopher

Uribe Armenta Javier

Enfoque Bioinspirado

PSO (Particle Swarm Optimization)

El PSO es un algoritmo inspirado en el comportamiento de enjambres de abejas buscando polen. Se usa principalmente para resolver problemas de optimización, como el control de drones autónomos o la coordinación de robots en tareas colaborativas.

Cómo se aplica el paradigma al ejemplo:

El algoritmo imita la forma en que los organismos en la naturaleza trabajan en equipo sin necesidad de un líder central. Cada agente del algoritmo ajusta su movimiento según su mejor experiencia y la de sus vecinos. Por ejemplo, los drones pueden compartir información entre ellos para mejorar sus rutas en tiempo real y optimizar su desplazamiento.

Beneficios

- Encuentra soluciones óptimas rápidamente.
- Es fácil de implementar y tiene bajo costo computacional comparado con otros métodos.
- Se adapta bien a entornos dinámicos, como robots o drones en movimiento.

Limitaciones

- Puede atascarse en soluciones subóptimas y no encontrar la mejor posible.
- Su rendimiento depende mucho de los parámetros como la inercia y la velocidad de exploración.
- En problemas muy complejos, no siempre garantiza la mejor solución global.

ACO (Ant Colony Optimization)

El ACO es un algoritmo basado en el comportamiento de las hormigas al buscar la mejor ruta entre su colonia y una fuente de alimento. Se usa en optimización de tráfico en ciudades y en la planificación de redes de telecomunicaciones, ayudando a encontrar caminos más eficientes.

Cómo se aplica el paradigma al ejemplo

El algoritmo imita la inteligencia colectiva de las hormigas, que dejan rastros de feromonas en los caminos más cortos para que otras las sigan. En aplicaciones como el tráfico, se pueden usar sensores para simular feromonas virtuales, marcando rutas congestionadas y sugiriendo caminos alternativos para evitar atascos y mejorar el flujo vehicular.

Beneficios

- Es distribuido y adaptable, funciona bien en entornos cambiantes como el tráfico.
- Encuentra soluciones cercanas a la óptima en problemas complejos.
- Escalable, se puede aplicar a sistemas grandes como redes de telecomunicaciones o logística.

Limitaciones

- Puede tardar en converger cuando el problema es muy grande.
- Depende mucho de parámetros como la evaporación de feromonas, lo que afecta su rendimiento.
- Es sensible a cambios bruscos, por lo que no siempre se adapta bien en tiempo real.

Enfoque Computacional

Detección de Fraude con Big Data

La detección de fraude con big data utiliza grandes volúmenes de datos transaccionales para identificar patrones inusuales que podrían indicar actividades fraudulentas. Se aplica principalmente en instituciones financieras como bancos, aseguradoras y plataformas de comercio electrónico para detectar fraudes en tiempo real y prevenir pérdidas económicas.

Cómo se aplica el paradigma al ejemplo:

Se aplica mediante el uso de algoritmos de aprendizaje automático y minería de datos para analizar grandes cantidades de transacciones y detectar patrones de comportamiento que podrían pasar desapercibidos por los humanos. Por ejemplo, un banco puede usar estos algoritmos para monitorear transacciones en tiempo real, identificar comportamientos sospechosos y bloquear operaciones fraudulentas antes de que se completen.

Beneficios

- Permite analizar grandes volúmenes de datos en tiempo real para detectar fraudes de manera más efectiva.
- Mejora la precisión al identificar patrones complejos de fraude que no serían fáciles de detectar manualmente.
- Reducción de costos asociados con el fraude, al poder prevenirlo antes de que ocurra.

Limitaciones

- Requiere grandes cantidades de datos de alta calidad para ser efectivo, lo que puede ser costoso de recopilar y mantener.
- Es sensible a los cambios en los patrones de fraude, lo que requiere ajustes constantes en los algoritmos.
- Riesgo de falsos positivos, donde transacciones legítimas pueden ser marcadas erróneamente como fraudulentas.

Minería de Datos

La minería de datos implica el proceso de extraer patrones y conocimientos útiles a partir de grandes volúmenes de datos. Es utilizada en diversos campos, como negocios, marketing, salud y redes sociales, para descubrir patrones ocultos que pueden ayudar en la toma de decisiones estratégicas.

Cómo se aplica el paradigma al ejemplo:

Se aplica para analizar grandes conjuntos de datos y encontrar relaciones, patrones y tendencias. Por ejemplo, en el ámbito del marketing, se utilizan técnicas de minería de datos para analizar comportamientos de los clientes y segmentarlos en grupos con preferencias similares, lo que ayuda a personalizar campañas publicitarias y mejorar las ventas.

Beneficios

Ayuda a descubrir patrones ocultos que no serían evidentes de otra manera.

Mejora la toma de decisiones estratégicas al proporcionar información basada en datos concretos.

Optimización de recursos, ya que permite identificar áreas de oportunidad y mejorar procesos.

Limitaciones

Requiere grandes volúmenes de datos de calidad, lo que puede ser difícil y costoso de obtener.

Posibilidad de interpretar mal los resultados si los algoritmos no están bien ajustados o si los datos no están limpios.

Dependencia de herramientas avanzadas y expertos, lo que puede aumentar la complejidad y el costo de implementación.

Proceso de aprendizaje automático

El aprendizaje automático es un proceso en el que se utilizan modelos matemáticos para que un sistema aprenda de los datos sin instrucciones directas. A través de algoritmos, el ML identifica patrones en los datos y los usa para hacer predicciones. A medida que el sistema recibe más datos y experiencia, sus resultados se vuelven más precisos, similar a cómo los humanos mejoran con la práctica.

Adquisición de datos.

La adquisición de datos implica recopilar datos sin procesar de diversas fuentes, como bases de datos, archivos, API o plataformas de transmisión. Los datos relevantes y de alta calidad son fundamentales para capacitar modelos de ML precisos. La incorporación de datos garantiza que el proceso tenga acceso a los datos necesarios para el análisis y el desarrollo de modelos.

Preprocesamiento de datos.

El preprocesamiento de datos abarca tareas como la limpieza, la transformación y la normalización de los datos sin procesar para que sean adecuados para el análisis y el modelado. El procesamiento previo ayuda a abordar problemas como valores faltantes, valores atípicos e inconsistencias en los datos, que podrían afectar negativamente el rendimiento del modelo si no se maneja. Garantiza que los datos estén en un formato consistente y utilizable para las etapas posteriores.

Entrenamiento del modelo.

Se elige un modelo de aprendizaje automático adecuado en función del problema y los datos disponibles. Existen varios tipos de modelos, como los árboles de decisión, los bosques aleatorios, las máquinas de vectores de soporte o las redes neuronales. A continuación, el modelo seleccionado se entrena con los datos preprocesados,

empleando técnicas como el aprendizaje supervisado y no supervisado, en función de la naturaleza del problema.

Evaluación del modelo.

La evaluación del modelo evalúa el rendimiento del modelo capacitado utilizando métricas como exactitud, precisión, recuperación, puntuación F1 o área bajo la curva (AUC). Esta evaluación ayuda a medir qué tan bien se generaliza el modelo para los datos no vistos e identifica cualquier problema potencial, como el sobreajuste o el subajuste. Proporciona información sobre las fortalezas y debilidades del modelo, guiando más iteraciones y mejoras.

Implementación del modelo.

Una vez que se obtiene un modelo satisfactorio, se implementa en el entorno de producción de la empresa. Para ello, se integra el modelo en los procesos empresariales, sistemas o aplicaciones existentes. Una vez implementado, resulta importante supervisar continuamente su rendimiento, detectar cualquier desviación, actualizarlo periódicamente a medida que se dispone de nuevos datos, y asegurarse de que sigue entregando información precisa y de valor.

Diferencias y similitudes entre el Modelo Cognitivo y el aprendizaje automático

Similitudes:

- Ambos procesos requieren que se obtengan datos para empezar. En el caso del modelo cognitivo, el ser humano obtiene información a través de los sentidos, mientras que en aprendizaje automático se recogen datos de distintas fuentes.
- En ambos casos, la información que se obtiene tiene que pasar por un proceso para que pueda usarse de manera adecuada. En los humanos, esto es interpretar y organizar lo que se ha percibido, y en el aprendizaje automático, se limpian y transforman los datos para que sean aptos para los algoritmos.
- Tanto en el aprendizaje humano como en el de las máquinas, hay una fase en la que se aprende de la experiencia. En los humanos, se aprende practicando y mejorando con el tiempo, mientras que en el aprendizaje automático, el modelo aprende patrones a partir de los datos que se le proporcionan.
- Después de aprender, tanto las personas como los modelos de ML se evalúan. Los humanos miden su progreso a través de su desempeño en tareas, y en el

aprendizaje automático, se usan métricas como precisión o exactitud para ver qué tan bien ha aprendido el modelo.

- Se ajustan las acciones después de recibir retroalimentación. En los humanos, se aprende de los errores y se mejora en la siguiente práctica, mientras que en el aprendizaje automático, se ajustan los parámetros del modelo después de evaluar su rendimiento.

Diferencias:

- La adquisición de datos en ML se refiere a la recolección estructurada de datos, mientras que la percepción cognitiva en los humanos implica un proceso más complejo que involucra interpretación subjetiva y procesos sensoriales dinámicos.
- El preprocesamiento de datos se enfoca en limpiar y transformar los datos para que sean útiles para el modelo. En contraste, el filtrado cognitivo en los humanos implica decidir qué información es relevante según el contexto, lo que puede ser mucho más flexible y dependiente de experiencias previas.
- Mientras que el entrenamiento del modelo en aprendizaje automático sigue un proceso matemático y estadístico, el aprendizaje humano está basado en la asimilación de experiencias, emociones y lógica, algo que no es fácilmente replicable por algoritmos.
- La evaluación de un modelo en ML se hace con métricas objetivas, como la precisión, mientras que, en los humanos, la reflexión cognitiva depende de cómo cada persona evalúa su desempeño y cómo mejora a partir de la experiencia.
- Después de que el modelo ha sido entrenado, se pasa a ponerlo en producción y se hace seguimiento a su desempeño. En los humanos, una vez aprendido algo, se aplica en la vida real, adaptándose a nuevas situaciones a medida que surgen.